

Relatório Técnico de Predição de Churn em Empresa Telefônica

1. Análise Exploratória de Dados (EDA)

Análise da base de dados:

- **Distribuições Multimodais:** os clientes não são todos iguais; eles se dividem claramente entre perfis de baixo custo e perfis premium.
- **Colinearidade Detectada:** o "Tempo de Casa" e o "Gasto Total" andam juntos. Isso significa alguns dados redundantes.
- **Segmentação de Risco:** O cancelamento (*churn*) está concentrado em quem tem faturas mais altas e internet mais rápida.

2. Pipeline de Pré-processamento e Data Engineering

Preparação dos dados:

- **Tratamento de Class Imbalance:** usamos **SMOTE** e **UnderSampling** porque tinha pouca base de dados de churn positivo.
- **Feature Selection (Mutual Information):** Filtro nas variáveis. O **valor da fatura** e a **velocidade de download** são os dados que mostram melhor a intenção de sair do cliente.

3. Treinamento e Estabilidade do Modelo

Sobre o modelo:

- **Curvas de Aprendizado:** O modelo é estável. Ele não está apenas decorando os dados (overfitting).
- **Métricas de Performance:** Alcançou um **ROC de 0.70**.

4. Avaliação de Métricas e Lift Analysis

O impacto real no negócio:

- **Ganho Acumulado:** Se focar nos **20% de clientes** que o modelo marcar como "críticos", consegue evitar **45% de todo o churn** da empresa.
- **Eficiência (Lift):** Usar esse modelo é **2,25 vezes mais eficiente** do que fazer campanhas aleatórias ou por intuição.

5. Diagnóstico Estratégico e Insights

Principais problemas:

- **O Plano da Fibra:** Clientes de Fibra Ótica cancelam **2x mais** (taxa de 26,2%). É um alerta sobre a qualidade ou preço desse serviço específico.
- **Retenção Contratual:** O contrato mensal é a maior base de churn. Clientes sem fidelidade saem mais que os outros.
- **Alvos Imediatos:** Clientes com faturas acima de **70€** e sem contrato fixo devem ser prioridade total para base de retenção.

O limitador atual do desempenho não é o algoritmo, nem engenharia de atributos, nem o modelo, mas o **dataset**.

6. Melhoras na Qualidade de Coleta dos Dados

Como coletar dados para o modelo:

- Integrar dados de **logs de suporte** (reclamações recentes) e **oscilações de consumo** (se o cliente parou de usar, ele está prestes a sair).
Para superar a barreira do dataset atual e maximizar o resultado, sugerimos a coleta de novas variáveis de **comportamento dinâmico**:
- **Tendência de Consumo:** Comparação do uso de dados entre o mês atual e a média dos últimos 6 meses.
- **Histórico de Suporte:** Número de tickets abertos nos últimos 30 dias (o maior sinalizador de insatisfação).
- **Pontualidade Financeira:** Histórico de atrasos no pagamento das últimas faturas.